

现代优化方法论文汇报

黄金鸣 郭镇涛

中国人民大学统计学院

2024 年 12 月 17 日



中國人民大學

RENMIN UNIVERSITY OF CHINA

① Introduction

② Data

③ Model

④ NN-Based Solution

⑤ Result



1 Introduction

2 Data

3 Model

4 NN-Based Solution

5 Result



问题背景 I

气候变化和天气风险在大规模影响着经济和生计，尤其是依赖于天气条件的农业生产。在实际中，天气指数保险可以用来对冲天气风险。天气指数保险的赔付完全基于一些预设的天气指数而不是受保人实际遭受的损失，因此它避免了传统赔付型保险相关的高行政成本、逆向选择和道德风险问题。

尽管前景广阔，但目前的天气指数保险需求较低，这是因为指数保险存在大的基差风险，即基础指数与实际损失之间的不匹配风险是导致地需求的原因之一。目前大多数指数保险基于低维度天气指数，并使用线性型赔付函数。图 (1) 显示了基于温度指数的线性保险的赔付情况，显示了较大的基差风险。

问题背景 II





图 1: Payoffs of Linear Index Insurance and Actual Losses


问题背景 III

Chen et al. 2024旨在通过两方面来减少基差风险。首先，作物生产依赖于高维度的天气指数。因此，在构建保险合同时，应该仔细选择并包含足够多的天气变量；其次，从生物学的角度来看，作物生产对天气条件的依赖时高度非线性的。


所以文章提出一种基于神经网络 (NN) 的指数保险设计。神经网络有助于捕捉天气指数与生产损失之间的高维度、非线性和复杂的相互作用。具体而言，我们将基于神经网络的方案嵌入到一个期望效用最大化问题中，并结合预算约束，以捕捉农民的保险需求。




(a)




(b)




(c)



(d)




(e)



(f)

我们还测试了基于 Linear72 模型预测的赔付款，如下图所示：

图 3: Linear72 contract





1 Introduction

2 Data

3 Model

4 NN-Based Solution

5 Result

数据方面，关于产量的损失我们采用伊利诺伊州 84 个县从 1925 至 2018 年的数据，我们假设玉米产量损失在去趋势化后在时间和空间上都是同质的，因此我们的样本量大小为 7869(84 个县 $\times$ 94 年 - 27 个缺失数据)；至于天气变量，由于天气的月际变化大而去特殊年份后不同的年份变化不明显，因此我们选取从 1925 至 2018 期间的所有 6 个天气指标在 12 个月的数据，即得到一个 72 维的天气指标矩阵。选取的天气指标如下表所示

表 1: 天气指数

Variable	Description
pcpn k	Total precipitation(rain+melted snow)for month k (mm)
tmax k	Daily maximum temperature averaged over all days in month k (°C)
tmin k	Daily minimum temperature averaged over all days in month k (°C)
dpt k	Daily mean dew point temperature averaged over all days in month k (°C)
vpdmax k	Daily maximum vapor pressure deficit averaged over all days in month k (hPa)
vpnmink k	Daily minimum vapor pressure deficit averaged over all days in month k (hPa)
k	Calendar month, that is, $k = 1, 2, \dots, 12$ for Jan-Dec



1 Introduction

2 Data

3 Model

4 NN-Based Solution

5 Result

本文的指数保险设计问题可以表述为以下的带约束的预期效用最大化问题：

$$\begin{cases} \sup_{I \in \mathcal{I}} & \mathbb{E}(U[w_0 - Y + I(\mathbf{X}) - \pi(I)]), \\ \text{s.t.} & P_L \leq \pi(I) \leq P_U \end{cases} \quad (1)$$

其中

- 农民的初始初始财富为 w_0 ;
- 每年面对的随机生产损失为 Y ;
- 指数保险赔付 $I(\mathbf{X})$ 由 p 维天气变量 $\mathbf{X} = (X_1, \dots, X_p)$ 决定, 其中 $I: \mathbb{R}^p \rightarrow \mathbb{R}^+$ 是一个非负赔付函数;
- 指数保险合约的保费 (premium) 为 $\pi(I)$, 是赔付函数的一个函数;
- 因此, 在指数保险存在的情况下, 农民的终端财富为 $w_0 - Y + I(\mathbf{X}) - \pi(I)$.

指数保险设计的目标是选择最优的赔付函数 I , 使投保人的预期效用 $\mathbb{E}(U)$ 在一定约束下达到最大化。本文重点针对生产损失的指数保险, 不考虑农作物价格风险, 即本文考虑的是收益保险。

我们需要计算预期效用以解决问题 (1)。但我们并不需要对损失 Y 和天气变量 $\mathbf{X}$ 的联合分布进行建模而是用它们的经验分布作为替代并直接寻找最优的指数保险策略。具体来说, 对于一个随机样本 $(\mathbf{X}, Y) : \{(\mathbf{x}_j, y_j)\}_{j=1, \dots, n}$, 其中 $\mathbf{x}_j = (x_{j1}, \dots, x_{jp})$, 用样本统计量替换数量后, 问题 (1) 可以重写为下面的最小化问题:

$$\begin{cases} \min_{I \in \mathcal{I}} & -\frac{1}{n} \sum_{j=1}^n U(w_0 - y_j + I(\mathbf{x}_j) - \pi_e(I)) \\ \text{s.t.} & P_L \leq \pi_e(I) \leq P_U, \end{cases} \quad (2)$$

其中 $\pi_e(I)$ 是 $\pi(I)$ 的经验替换, 由 $\pi_e(I) := (\lambda/n) \sum_{j=1}^n I(\mathbf{x}_j)$ 给出。

考虑一个典型的玉米种植农民，其效用函数为负指数型效用函数 $U(w) = -(1/\alpha)e^{-\alpha w}$, $\alpha > 0$ 是绝对风险厌恶系数，在这里我们取 $\alpha = 0.008$ 。

至于保费，本文采用文献和实践中最常用的保费原理来确定指数保险合同的保费，即预期保费原理。即指数保险费 $\pi(I)$ 与期望赔付成比例，如下所示：

$$\pi(I) = \lambda \mathbb{E}[I(\mathbf{X})], \quad (3)$$

其中 λ 是风险载荷参数且 $\lambda \geq 1$ ¹。

¹文章根据保险合同的供给需求曲线内生地确定均衡 λ ，具体步骤如下：首先，通过美国工业部 SOB 报告的市场数据来拟合供给曲线 $Cov = f_S(\lambda)$ ，文章使用历史数据采用非线性最小二乘法将曲线拟合为 λ 的幂函数，拟合的供给曲线为 $Cov = f_S(\lambda) = 7.04\lambda^{2.92} + 12.83$ ；其次，对于给定 $\lambda \in [1.02, 1.5]$ (这个区间涵盖了指数保险在实际中可行的加载参数)。我们使用基于神经网络的方法获得对应的最佳指数保险覆盖。通过得到 λ 和最佳覆盖的配对数据，我们使用三次 Hermite 插值多项式拟合需求曲线 $Cov = f_D(\lambda)$ 。最后将供给和需求函数 $f_S(\lambda) = f_D(\lambda)$ 联立求解得出市场均衡下的加载参数 λ^* 。




图 4: Supply and Demand Curves of the Index Insurance

1 Introduction

2 Data

3 Model

4 NN-Based Solution

Neural Networks and Feasible Set

罚函数法

增广 Lagrange 法

5 Result



1 Introduction

2 Data

3 Model

4 NN-Based Solution

Neural Networks and Feasible Set

罚函数法

增广 Lagrange 法

5 Result



Feasible Set I


现有文献和业界通常考虑一个限制性较强的可行集 $\tilde{\mathcal{I}}_0 \subset \mathcal{I}$, 比如阶跃函数（即当某些预定事件发生时触发保险赔付）和分段线性函数（即触发的赔付是指数的线性函数）就是文献中常用的函数形式。然而限制性可行集会导致合同存在较大的基础风险，导致指数保险市场的失败。

本文中我们应用神经网络来寻找在扩展的可行集 $\mathcal{I}_0 \subset \mathcal{I}$ 中的最优合同。 $\mathcal{I}_0$ 应该足够大，以包含能够捕捉高维度指数与损失之间复杂（非线性、非单调）关系的候选赔付函数，同时 $\mathcal{I}_0$ 也该排除那些在样本数据上非常敏感、无法作为适当保险合同的“表现不稳定”的函数，这样的权衡如图 (5) 所示。

Neural Network

我们分别考虑了各种多层的全连接神经网络，其中激活函数使用 RELU。经过比较后，我们选择使用一个 3 层的神经网络 (64n16n16n) 来作为我们的可行集 $\mathcal{I}_0$ 。

图 6: An illustration of neural networks with H -hidden layers



1 Introduction

2 Data

3 Model

4 NN-Based Solution

Neural Networks and Feasible Set

罚函数法

增广 Lagrange 法

5 Result



Solving for the Optimal Policy Using a Penalty Method

为了解决优化目标存在约束的问题，文章考虑使用罚函数定义一系列无约束的问题 $\{\Phi_k\}_{k \geq 0}$:

$$\Phi_k = \min_{I \in \mathcal{I}_0} \left(-\frac{1}{n} \sum_{j=1}^n U(w - Y_j + I(\mathbf{x}_j) - \pi_e(I)) + \phi_k \cdot g(I) \right), \quad (4)$$

其中 $\{\phi_k\}$ 是一列递增的非负实函数，随着 k 的增大趋向于正无穷， $g(I)$ 即是惩罚函数。惩罚函数由如下的误差的平方和定义：

$$g(I) = [\max(\pi_e(I) - P_U, 0)]^2 + [\max(P_L - \pi_e(I), 0)]^2.$$

Solve for the Optimal index insurance policy

Algorithm 1: Solve for the Optimal index insurance policy

Output: An optimal index insurance policy I

Input: Index data X and loss data Y

- 1 Build and initialize a neural network;
- 2 Initialization: $k = 0, \phi_0 = \epsilon_1, \rho > 1$, obtain I by solving an unconstrained problem Φ_0 ;
- 3 **while** $|I - I_{last}| > \epsilon_3$ **or** $|\pi_e(I) - \pi_e(I_{last})| > \epsilon_4$ **do**
- 4 Set $I_{last} = I, \pi_e(I_{last}) = \pi_e(I)$;
- 5 Update $k \leftarrow k + 1, \phi_{k+1} = \rho \phi_k$;
- 6 Train the neural network and obtain the optimal I for problem $\Phi_K(I)$:

$$\Phi_k(I) = -\frac{1}{n} \sum_{j=1}^n U(w - y_j + I(\mathbf{x}_j) - \pi_e(I)) + \phi_k \cdot g(I),$$

where the loss function is customized according to $\Phi_k(I)$
and I_{last} is set to the initial value of optimization;

- 7 Update $g(I)$ and $\pi_e(I)$;

8 **end**

- 9 **return** (I);
-

1 Introduction

2 Data

3 Model

4 NN-Based Solution

Neural Networks and Feasible Set

罚函数法

增广 Lagrange 法

5 Result



Solve for the Optimal Policy using a generalized Lagrange method

这里我们只有不等式约束，所以令

$$\phi_i(I) = \begin{cases} -\frac{\lambda_i^2}{2\sigma}, & c_i(I) \geq \frac{\lambda_i}{\sigma}, \\ \frac{1}{2}\sigma \left[\left(c_i(I) - \frac{\lambda_i}{\sigma} \right)^2 - \frac{\lambda_i^2}{\sigma^2} \right], & c_i(I) \leq \frac{\lambda_i}{\sigma}, \end{cases} \quad (5)$$

其中 $c_1(I) = \pi_e(I) - P_L, c_2(I) = P_U - \pi_e(I)$ 。并得到增广 Lagrange 函数

$$\Phi(I, \lambda, \sigma) = -\frac{1}{n} \sum_{j=1}^n U(w - Y_j + I(\mathbf{x}_j) - \pi_e(I)) + \sum_i \phi_i(I).$$

Solve for the Optimal Policy using a generalized Lagrange method

Algorithm 2: Solve for the Optimal index insurance policy

Output: 一个最优的指数保险策略 I

Input: 天气指数数据 $\mathbf{X}$ 以及损失 Y

- 1 构造并初始化一个神经网络;
 - 2 初始化: $k = 0, \epsilon > 0, \lambda_i^0 > 0, \sigma_0 > 0, \rho > 1$;
 - 3 **while** $[\min\{\pi_e^k(I) - P_L, \frac{\lambda_1^k}{\sigma_k}\}^2 + \min\{P_U - \pi_e^k(I), \frac{\lambda_2^k}{\sigma_k}\}^2]^{1/2} > \epsilon$
do
 - 4 $I_{last} = I$;
 - 5 以 I_{last} 为初始位置训练损失函数为 $\Phi(x, \lambda^k, \sigma_k)$ 的神经网络, 并得到此时的最优指数保险 I ;
 - 6 更新 $\lambda^k, \sigma_k, \lambda_1^{k+1} = -\sigma_k \min\{\pi_e^k(I) - P_L - \lambda_1^k/\sigma_k, 0\}$,
 $\lambda_2^{k+1} = -\sigma_k \min\{P_U - \pi_e^k(I) - \lambda_2^k/\sigma_k, 0\}, \sigma_{k+1} = \rho\sigma_k$;
 - 7 $k \leftarrow k + 1$;
 - 8 **end**
 - 9 **return** (I) ;
-



① Introduction

② Data


③ Model

④ NN-Based Solution


⑤ Result

Result with Penalty Method I

我们考虑以下情况： $w_0 = 389$, $P_L = 5$, $P_U = 500$ ，并且按照时间顺序把前 70% 分为训练集，中间 15% 被分为验证集，最后 15% 被分为测试集。先使用罚函数法，罚函数系数 $\phi_0 = 10^{-6}$ ， $\phi_{k+1} = 1.2\phi_k$ ，并且当 $\phi_k \geq 0.1$ 时终止训练，最后结果如下：



(a) Rmsprop



(b) Adam

图 7: Utility and Premium Change During Training with Penalty

Result with Penalty Method II

表 2: Result with Penalty Method using Rmsprop

	train	valid	test
U with insurance	-3.48252	-3.15697	-2.99893
U w/o insurance	-3.87798	-3.20684	-3.1225
U improvement(%)	10.1976	1.555	3.9573
CEW with insurance	447.5698	459.8376	466.2571
CEW w/o insurance	434.125	457.8786	461.21
CEW improvement	13.44478	1.959049	5.047125
CEW improvement (%)	0.03097	0.004279	0.010943
Premium	31.3519	16.605	16.76953


Result with Penalty Method III

表 3: Result with Penalty Method using Adam


	train	valid	test
U with insurance	-3.46919	-3.08229	-2.9239
U w/o insurance	-3.87798	-3.20684	-3.1225
U improvement(%)	10.5413	3.8838	6.3604
CEW with insurance	448.0491	462.8301	469.4246
CEW w/o insurance	434.125	457.8786	461.21
CEW improvement	13.92411	4.951489	8.214612
CEW improvement (%)	0.032074	0.010814	0.017811
Premium	32.58364	15.9892	17.72511

Result with Augmented Lagrange Method I

除了本文考虑的罚函数方法，我们还使用了增广拉格朗日法，并且参数 $\epsilon = 10^{-8}$, $\lambda_i^0 = 2$, $\sigma = 10^{-3}$, $\rho = 1.2$ 。最终结果如下图和下表所示



(a) Rmsprop



(b) Adam

图 8: Utility and Premium Change During Training with Augmented Lagrange

Result with Augmented Lagrange Method II

表 4: Result with generalized Lagrange using Rmsprop


	train	valid	test
U with insurance	-3.55105	-3.05053	-2.90317
U w/o insurance	-3.87798	-3.20684	-3.1225
U improvement(%)	8.4302	4.8742	7.0242
CEW with insurance	445.1337	464.1249	470.3139
CEW w/o insurance	434.125	457.8786	461.21
CEW improvement	11.00863	6.24629	9.10392
CEW improvement (%)	0.025358	0.013642	0.019739
Premium	37.28808	36.67967	37.03973

Result with Augmented Lagrange Method III


表 5: Result with generalized Lagrange using Adam

	train	valid	test
U with insurance	-3.54797	-3.03919	-2.89323
U w/o insurance	-3.87798	-3.20684	-3.1225
U improvement(%)	8.5098	5.2278	7.3425
CEW with insurance	445.2423	464.5903	470.7425
CEW w/o insurance	434.125	457.8786	461.21
CEW improvement	11.11727	6.711718	9.532487
CEW improvement (%)	0.025608	0.014658	0.020668
Premium	35.74396	34.18185	34.58889

An optimal NN-based contract



- [1] Zhanhui Chen et al. “Managing Weather Risk with a Neural Network-Based Index Insurance”. In: *Management Science* 70.7 (2024), pp. 4306–4327 (cit. on p. 6).



Thanks!

